

Segundo Reporte

Julian Gaitan

2026-04-26

Índice

1. Introducción.	1
2. Objetivo	1
3. Pregunta problema	1
4. Parte 1: Introducción y Análisis previo de los datos.	1
4.1. Ajuste de tipos de datos.	1
4.2. Modificación de tipos de datos.	2
4.3. Eliminación preliminar de variables.	2
4.4. Valores únicos	2
4.5. Datos nulos	4
4.6. Graficos de dispersion de la variable objetivo con respecto a variables explicativas.	5
4.7. Graficos de dispersión entre las variables explicativas	19
4.8. Evaluación de colinealidad	19
4.9. Distribuciones de las variables categóricas	21
4.10. Conclusiones - Parte 1	21
5. Parte 2: Estimación de modelos, ajuste y validación.	21
5.1. Modelo Completo	21
5.2. Comprobación de supuestos del modelo completo	25
5.3. Modelo transformado (log (precio))	27
5.4. Modelo transformado log (precio) y log(area)	35
5.5. Comprobación de supuestos del segundo modelo transformado (+log area) . . .	38
5.6. Modelo con pesos	39
5.7. Comprobación de supuestos de modelo con pesos	42

6. Parte 3: Exploración profunda del modelo final.	44
6.1. <i>Confusión</i>	44
6.2. <i>Interacción entre variables</i>	49
6.3. <i>Apalancamiento y análisis de observaciones influyentes</i>	52
6.4. <i>Selección de variables usando criterios de informacion</i>	56
6.5. <i>Validación y pronósticos del modelo.</i>	67
7. Interpretacion final	68
7.1. Rango	69
8. Conclusiones y hallazgos relevantes	69
9. Recomendaciones futuras	70
10. Anexos	70
10.1. 1. Modelos calculados con estrato numérico:	71



Pontificia Universidad Javeriana

Análisis del Precio de Vivienda en Bogota (2023)

Ciencia de Datos

Julian Camilo Gaitan Contreras
Profesor: Gabriel Camilo Perez Castañeda

26 de abril de 2026

1. Introducción.

El presente conjunto de datos almacena propiedades de finca raíz en la ciudad de bogotá, para el año 2023

2. Objetivo

Crear un modelo de regresión lineal múltiple para predecir el precio de un inmueble en venta de la ciudad de Bogotá para el año 2023

3. Pregunta problema

¿Cual será el precio de un apartamento en venta en Bogotá para el año 2023 según sus características inmobiliarias?

4. Parte 1: Introducción y Análisis previo de los datos.

En este apartado se realizarán ajustes previos al conjunto de datos.

4.1. Ajuste de tipos de datos.

```
## cols(  
##   conjunto = col_character(),  
##   administración = col_double(),  
##   estrato = col_double(),  
##   antigüedad = col_double(),  
##   remodelado = col_character(),  
##   área = col_double(),  
##   habitaciones = col_double(),  
##   baños = col_double(),  
##   garajes = col_double(),  
##   elevadores = col_double(),  
##   tipo_de_inmueble = col_character(),  
##   deposito = col_double(),  
##   porteria = col_character(),  
##   zona_de_lavanderia = col_character(),  
##   gas = col_character(),  
##   parqueadero = col_character(),  
##   precio = col_double(),  
##   direccion = col_character(),  
##   nombre = col_character(),  
##   descripcion = col_character(),  
##   barrio = col_character()  
## )
```

4.2. Modificación de tipos de datos.

4.3. Eliminación preliminar de variables.

Se eliminan variables descriptivas de los inmuebles que no tienen relevancia en el problema

```
## administracion      estrato      antiguedad      remodelado      area
## Min.      :      0      1      : 15      Min.      : 0.00      No      :335      Min.      : 26.00
## 1st Qu.: 74000      2      :171      1st Qu.: 7.00      Si      :247      1st Qu.: 47.00
## Median : 135000      3      :212      Median :13.00      NA's:   3      Median : 55.00
## Mean    : 205470      4      :116      Mean    :15.13                      Mean    : 60.46
## 3rd Qu.: 272000      5      : 47      3rd Qu.:21.00                      3rd Qu.: 70.00
## Max.    :1976535      6      : 22      Max.    :48.00                      Max.    :207.00
##                                     NA's:   2
## habitaciones      banos          garajes          elevadores
## Min.    :1.000      Min.    :0.000      Min.    :0.0000      Min.    :0.0000
## 1st Qu.:2.000      1st Qu.:1.000      1st Qu.:0.0000      1st Qu.:0.0000
## Median :3.000      Median :2.000      Median :0.0000      Median :0.0000
## Mean    :2.593      Mean    :1.648      Mean     :0.4821      Mean     :0.5709
## 3rd Qu.:3.000      3rd Qu.:2.000      3rd Qu.:1.0000      3rd Qu.:1.0000
## Max.    :8.000      Max.    :4.000      Max.     :3.0000      Max.     :4.0000
##
##                                     tipo_de_inmueble deposito      porteria      zona_de_lavanderia
## Apartamento                      :547      0:473      24 hrs:540      Comunal : 54
## Casa                             :   8      1:112      No      : 45      No Tiene:531
## casa con conjunto cerrado: 30
##
##
##
##
## gas      parqueadero      precio
## No   :   6      No:164      Min.    :8.500e+07
## Si   :549      Si:421      1st Qu.:1.520e+08
## NA's: 30                      Median :2.184e+08
##                               Mean    :2.608e+08
##                               3rd Qu.:3.520e+08
##                               Max.    :1.530e+09
##
```

4.4. Valores únicos


```
## $estrato
## [1] 4      6      3      5      2      1      <NA>
## Levels: 1 2 3 4 5 6
##
## $remodelado
## [1] Si      No      <NA>
## Levels: No Si
##
```

```

## $tipo_de_inmueble
## [1] Apartamento          Casa
## [3] casa con conjunto cerrado
## Levels: Apartamento Casa casa con conjunto cerrado
##
## $deposito
## [1] 0 1
## Levels: 0 1
##
## $porteria
## [1] 24 hrs No
## Levels: 24 hrs No
##
## $zona_de_lavanderia
## [1] No Tiene Comunal
## Levels: Comunal No Tiene
##
## $gas
## [1] Si    <NA> No
## Levels: No Si
##
## $parqueadero
## [1] No Si
## Levels: No Si

```


4.5. Datos nulos





- En total hay 35 datos nulos en todo el conjunto de datos.
- De los 35 datos nulos la mayoría provienen de 'gas'.
- la proporción de datos nulos sobre el conjunto total es de : 0.0598291.

Se procede a eliminar las filas con valores nulos.


4.6. Graficos de dispersion de la variable objetivo con respecto a variables explicativas






No se observan relaciones no-lineales.

```
## [[1]]
```




```
##
```

```
## [[2]]
```




##

[[3]]




##

[[4]]




##

[[5]]




##

[[6]]




##

[[7]]




##

[[8]]




##

[[9]]




##

[[10]]




```
##  
## [[11]]
```




##

[[12]]




Se observan relaciones lineales entre las variables categoricas y el precio usando las distribuciones de precio por cada valor categórico como referencia.

4.7. Graficos de dispersión entre las variables explicativas




4.8. Evaluación de colinealidad

Se observan algunas variables explicativas que tienen correlaciones entre sí .



4.9. Distribuciones de las variables categóricas



Los desbalances en variables categóricas pueden incidir en la significancia de sus valores al momento de calcular el modelo.

4.10. Conclusiones - Parte 1

- No se observaron relaciones no-lineales de las variables explicativas con respecto a la variable objetivo.
- No se realizarán transformaciones de variables hasta el momento con el fin de conservar interpretabilidad del modelo y también teniendo en cuenta que se observaron relaciones lineales en el conjunto de datos. En la parte 2 se evaluará si es necesario transformar al comprobar los supuestos del modelo
- Respecto a los valores de correlación hallados, se concluye que existe colinealidad NO perfecta entre algunas variables. En la parte 2 se evaluará si es necesario retirar o transformar variables del modelo.

5. Parte 2: Estimación de modelos, ajuste y validación.


En este apartado se harán estimaciones de modelos, ajustes y validaciones.



5.1. Modelo Completo


##


```
## Call:
## lm(formula = precio ~ ., data = propiedades)
##
## Residuals:
##      Min        1Q      Median        3Q       Max
## -157073489  -24390346   989930  19909121  328417468
##
## Coefficients:
##              Estimate Std. Error t value
## (Intercept)      4.134e+06  2.485e+07  0.166
## administracion    1.948e+02  1.854e+01 10.506
## estrato2          1.002e+07  1.243e+07  0.806
## estrato3          3.528e+07  1.293e+07  2.728
## estrato4          7.711e+07  1.457e+07  5.291
## estrato5          7.134e+07  1.702e+07  4.192
## estrato6          7.321e+07  1.910e+07  3.832
## antiguedad       -1.308e+06  2.559e+05 -5.113
## remodeladoSi     -5.509e+06  4.039e+06 -1.364
## area              3.284e+06  1.959e+05 16.763
## habitaciones     -1.023e+07  3.755e+06 -2.724
## banos             1.721e+07  4.605e+06  3.737
## garajes           3.021e+07  5.282e+06  5.719
## elevadores        4.712e+06  3.221e+06  1.463
## tipo_de_inmuebleCasa 8.288e+07  1.744e+07  4.751
## tipo_de_inmueblecasa con conjunto cerrado 4.816e+06  9.389e+06  0.513
## depositoSi       1.139e+07  6.064e+06  1.878
## porteriaSi        -2.179e+07  7.828e+06 -2.784
## zona_de_lavanderiaSi 1.542e+07  6.907e+06  2.233
## gasSi             -4.769e+06  1.883e+07 -0.253
## parqueaderoSi     1.882e+06  4.648e+06  0.405
##
##              Pr(>|t|)
## (Intercept)    0.867975
## administracion < 2e-16 ***
## estrato2       0.420515
## estrato3       0.006581 **
## estrato4       1.78e-07 ***
## estrato5       3.24e-05 ***
## estrato6       0.000142 ***
## antiguedad     4.44e-07 ***
## remodeladoSi   0.173128
## area           < 2e-16 ***
## habitaciones   0.006663 **
## banos          0.000206 ***
## garajes        1.79e-08 ***
## elevadores     0.144057
## tipo_de_inmuebleCasa 2.61e-06 ***
## tipo_de_inmueblecasa con conjunto cerrado 0.608205
## depositoSi     0.060946 .
## porteriaSi     0.005567 **
## zona_de_lavanderiaSi 0.025973 *
```

```
## gasSi                                0.800207
## parqueaderoSi                        0.685772
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 45150000 on 530 degrees of freedom
## Multiple R-squared:  0.9116, Adjusted R-squared:  0.9082
## F-statistic: 273.1 on 20 and 530 DF,  p-value: < 2.2e-16
```







- De acuerdo al resumen, hay algunas variables no significativas para estimar el precio.
- De acuerdo a 'Residuals vs Fitted', los residuos no tienen comportamiento constante a medida que aumenta el valor predicho de precio, podría sugerir heterocedasticidad
- De acuerdo a scale-location, puede existir heterocedasticidad porque los errores son menores a precios menores y viceversa.
- De acuerdo al QQplot, podría decirse pero no afirmarse que los residuos NO se distribuyen normalmente, al parecer por colas en valores extremos
- De acuerdo al 'residuals vs leverage' existen observaciones muy influyentes

5.2. Comprobación de supuestos del modelo completo

5.2.1. 1. Prueba de linealidad Y vs X - Test de Ramsey

H_0 : El modelo está correctamente especificado (no hay variables omitidas ni no linealidad).

H_1 : El modelo está mal especificado (existen variables omitidas o no linealidad).

```
##
## RESET test
##
## data:  mod
## RESET = 59.497, df1 = 2, df2 = 528, p-value < 2.2e-16
```

Se rechaza la hipótesis nula con $\alpha=0.05$, Hay no - linealidad o variables omitidas o comportamientos exponenciales no captados

5.2.2. * 2. Prueba de Breusch Pagan - Homocedasticidad *

$$H_0 : \text{Var}(\varepsilon_i) = \sigma^2 \quad (\text{los errores tienen varianza constante})$$

$$H_1 : \text{Var}(\varepsilon_i) \neq \sigma^2 \quad (\text{existe heterocedasticidad})$$

```
##
## studentized Breusch-Pagan test
##
## data: mod
## BP = 227.79, df = 20, p-value < 2.2e-16
```

Se rechaza la hipótesis nula con $\alpha=0.05$, no existe homocedasticidad de los errores. Existe heterocedasticidad en el modelo completo

5.2.3. * 3. Prueba de autocorrelacion de los errores - Durbin Watson *

$$H_0 : \rho = 0 \quad (\text{no hay autocorrelación de los errores})$$

$$H_1 : \rho \neq 0 \quad (\text{los errores están correlacionados})$$

```
##
## Durbin-Watson test
##
## data: mod
## DW = 2.1299, p-value = 0.9348
## alternative hypothesis: true autocorrelation is greater than 0
```

NO se rechaza la hipótesis nula de que los errores son dependientes entre sí, se puede decir que los errores son independientes entre si (ortogonales)

5.2.4. * 4. Prueba de normalidad de los errores- Shapiro *

$$H_0 : \varepsilon_i \sim N(0, \sigma^2) \quad (\text{los residuos son normalmente distribuidos})$$

$$H_1 : \varepsilon_i \not\sim N(0, \sigma^2) \quad (\text{los residuos no son normales})$$

```
##
## Shapiro-Wilk normality test
##
## data: mod$residuals
## W = 0.91516, p-value < 2.2e-16
```

Se rechaza la hipótesis nula con un nivel de significancia de 0.05 de que el vector dado(residuales) tiene una distribución normal. No hay normalidad de los residuales

5.2.5. VIF - verificación de inflación de varianza por colinealidad

```
##              GVIF Df GVIF^(1/(2*Df))
## administracion 3.772696 1      1.942343
## estrato        4.344021 5      1.158215
## antigüedad     1.721108 1      1.311910
## remodelado     1.084943 1      1.041606
## area          4.653973 1      2.157307
## habitaciones   1.900581 1      1.378615
## banos          2.365187 1      1.537917
## garajes        2.918050 1      1.708230
## elevadores     1.593731 1      1.262431
## tipo_de_inmueble 1.300264 2      1.067844
## deposito      1.499210 1      1.224422
## porteria       1.114959 1      1.055916
## zona_de_lavanderia 1.063745 1      1.031380
## gas           1.032673 1      1.016205
## parqueadero    1.156848 1      1.075569
```

Ningún VIF sobrepasa 5, **No hay inflación de varianza significativa por colinealidad**

En esta parte se buscará dar solución a los problemas de supuestos encontrados en el modelo completo.

En el modelo completo se observó heterocedasticidad; tendencia al aumento del error en función directa del aumento de precio predicho.

También observamos no - normalidad de los errores.


Por esta razón se procederá a escalar la variable precio; con el fin de que los valores sean mas pequeños y queden en una escala común



Se procederá a eliminar del modelo las variables no significativas.


5.3. Modelo transformado (log (precio))

```
##
## Call:
## lm(formula = log(precio) ~ administracion + estrato + antigüedad +
##     area + habitaciones + banos + garajes + elevadores + esCasa +
##     zona_de_lavanderia, data = propiedades)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.42542 -0.09772  0.00109  0.10413  0.46361
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   1.821e+01  4.891e-02 372.271 < 2e-16 ***
## administracion 1.952e-07  6.177e-08   3.160 0.001664 **
## estrato2      5.747e-02  4.190e-02   1.372 0.170718
## estrato3      3.299e-01  4.352e-02   7.580 1.54e-13 ***
## estrato4      5.501e-01  4.899e-02  11.228 < 2e-16 ***
```

```
## estrato5          5.730e-01  5.698e-02  10.055 < 2e-16 ***
## estrato6          5.950e-01  6.353e-02   9.365 < 2e-16 ***
## antiguedad       -1.371e-03  8.427e-04  -1.627 0.104282
## area             6.755e-03  6.491e-04  10.405 < 2e-16 ***
## habitaciones     -1.440e-03  1.255e-02  -0.115 0.908659
## banos            1.173e-01  1.553e-02   7.552 1.86e-13 ***
## garajes          1.544e-01  1.758e-02   8.780 < 2e-16 ***
## elevadores       3.750e-02  1.070e-02   3.503 0.000499 ***
## esCasaSi         2.419e-01  5.772e-02   4.191 3.24e-05 ***
## zona_de_lavanderiaSi 5.801e-02  2.309e-02   2.513 0.012279 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1526 on 536 degrees of freedom
## Multiple R-squared:  0.9107, Adjusted R-squared:  0.9084
## F-statistic: 390.5 on 14 and 536 DF,  p-value: < 2.2e-16
```










lm(log(precio) ~ administracion + estrato + antigüedad + area + habitacione ...


Se observan nuevas variables no significativas, se recalculará el modelo:

```
##
## Call:
## lm(formula = log(precio) ~ +estrato + area + banos + garajes +
##     elevadores + esCasa + zona_de_lavanderia, data = propiedades)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.42190 -0.09797 -0.00907  0.10398  0.48543
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    1.818e+01  4.531e-02 401.183 < 2e-16 ***
## estrato2        5.518e-02  4.177e-02   1.321 0.187047
## estrato3        3.249e-01  4.257e-02   7.632 1.06e-13 ***
## estrato4        5.526e-01  4.618e-02  11.966 < 2e-16 ***
## estrato5        5.987e-01  5.171e-02  11.579 < 2e-16 ***
## estrato6        6.314e-01  5.800e-02  10.886 < 2e-16 ***
## area            7.382e-03  5.161e-04  14.302 < 2e-16 ***
## banos           1.152e-01  1.513e-02   7.609 1.24e-13 ***
## garajes         1.654e-01  1.746e-02   9.474 < 2e-16 ***
## elevadores      4.960e-02  9.531e-03   5.204 2.77e-07 ***
## esCasaSi        2.057e-01  5.662e-02   3.634 0.000306 ***
## zona_de_lavanderiaSi 5.253e-02  2.312e-02   2.272 0.023491 *
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1541 on 539 degrees of freedom
## Multiple R-squared:  0.9084, Adjusted R-squared:  0.9065
## F-statistic: 485.9 on 11 and 539 DF,  p-value: < 2.2e-16
```







$\text{lm}(\log(\text{precio}) \sim +\text{estrato} + \text{area} + \text{banos} + \text{garajes} + \text{elevadores} + \text{esCasa} + \dots$

Se ha eliminado administración porque no resultó significativa. ### ## Comprobación de supuestos del modelo transformado

5.3.1. * 1. Prueba de linealidad Y vs X - Test de Ramsey *

H_0 : El modelo está correctamente especificado (no hay variables omitidas ni no linealidad).

H_1 : El modelo está mal especificado (existen variables omitidas o no linealidad).

```
##
## RESET test
##
## data: mod_transformado
## RESET = 31.922, df1 = 2, df2 = 534, p-value = 8.027e-14
```

Se rechaza la hipótesis nula con un nivel de significancia de 0.05, Hay no - linealidad o variables omitidas o comportamientos exponenciales no captados

5.3.2. * 2. Prueba de Breusch Pagan - Homocedasticidad *

H_0 : $\text{Var}(\varepsilon_i) = \sigma^2$ (los errores tienen varianza constante)

H_1 : $\text{Var}(\varepsilon_i) \neq \sigma^2$ (existe heterocedasticidad)

```
##
## studentized Breusch-Pagan test
##
## data: mod_transformado_rest
## BP = 38.418, df = 11, p-value = 6.65e-05
```

Se rechaza la hipótesis nula con $\alpha=0.05$, no existe homocedasticidad de los errores. Existe heterocedasticidad en el modelo completo

5.3.3. * 3. Prueba de autocorrelacion de los errores - Durbin Watson *

$$H_0 : \rho = 0 \quad (\text{no hay autocorrelación de los errores})$$

$$H_1 : \rho \neq 0 \quad (\text{los errores están correlacionados})$$

```
##
## Durbin-Watson test
##
## data: mod_transformado_rest
## DW = 2.0711, p-value = 0.7965
## alternative hypothesis: true autocorrelation is greater than 0
```

NO se rechaza la hipótesis nula de que los errores son dependientes entre sí, se puede decir que los errores son independientes entre si (ortogonales)

5.3.4. * 4. Prueba de normalidad de los errores- Shapiro *

$$H_0 : \varepsilon_i \sim N(0, \sigma^2) \quad (\text{los residuos son normalmente distribuidos})$$

$$H_1 : \varepsilon_i \not\sim N(0, \sigma^2) \quad (\text{los residuos no son normales})$$

```
##
## Shapiro-Wilk normality test
##
## data: mod_transformado_rest$residuals
## W = 0.99706, p-value = 0.4272
```

NO se rechaza la hipótesis nula con un nivel de significancia de 0.05 de que el vector dado(residuales) tiene una distribución normal.hay normalidad de los residuales

5.3.5. *VIF - verificacion de inflación de varianza por colinealidad*

	GVIF	Df	GVIF^(1/(2*Df))
estrato	2.541003	5	1.097743
area	2.774623	1	1.665720
banos	2.193744	1	1.481129
garajes	2.737788	1	1.654626



```
## elevadores      1.198426  1      1.094727
## esCasa          1.064528  1      1.031760
## zona_de_lavanderia 1.024036  1      1.011947
```



Ningún VIF sobrepasa 5, **No hay inflación de varianza significativa por colinealidad**

Para este modelo se logró pasar la prueba de normalidad gracias a la transformación de la variable Y (precio), sin embargo el problema de heterocedasticidad sigue presente, se intentará escalar area, para dejar las variables numéricas en escalas similares y ver si esta variable predictora puede estar generando esta heterocedasticidad. (Nótese que previamente se ha eliminado administración o por no significancia)

5.4. Modelo transformado log (precio) y log(area)

```
##
## Call:
## lm(formula = log(precio) ~ estrato + log(area) + banos + garajes +
##     elevadores + esCasa + zona_de_lavanderia, data = propiedades)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.42151 -0.10432 -0.00575  0.09881  0.52566
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    16.453143   0.146398  112.386 < 2e-16 ***
## estrato2        0.066951   0.042022   1.593  0.1117
## estrato3        0.320529   0.042745   7.499 2.67e-13 ***
## estrato4        0.552777   0.046396  11.914 < 2e-16 ***
## estrato5        0.598976   0.051948  11.530 < 2e-16 ***
## estrato6        0.642135   0.058262  11.022 < 2e-16 ***
## log(area)       0.541214   0.038490  14.061 < 2e-16 ***
## banos          0.099364   0.015850   6.269 7.45e-10 ***
## garajes         0.163949   0.017615   9.308 < 2e-16 ***
## elevadores      0.052793   0.009582   5.510 5.57e-08 ***
## esCasaSi        0.226171   0.056957   3.971 8.13e-05 ***
## zona_de_lavanderiaSi 0.054316  0.023232   2.338  0.0198 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1548 on 539 degrees of freedom
## Multiple R-squared:  0.9076, Adjusted R-squared:  0.9057
## F-statistic:  481 on 11 and 539 DF, p-value: < 2.2e-16
```





5.5. Comprobación de supuestos del segundo modelo transformado (+log area)

5.5.1. * 1. Prueba de linealidad Y vs X - Test de Ramsey *

H_0 : El modelo está correctamente especificado (no hay variables omitidas ni no linealidad).

H_1 : El modelo está mal especificado (existen variables omitidas o no linealidad).

```
##  
## RESET test  
##  
## data: mod_transformado2  
## RESET = 0.99039, df1 = 2, df2 = 537, p-value = 0.3721
```

Se rechaza la hipótesis nula con $\alpha=0.05$, Hay linealidad y no existen variables omitidas o comportamientos exponenciales no captados

5.5.2. * 2. Prueba de Breusch Pagan - Homocedasticidad *

$H_0 : \text{Var}(\varepsilon_i) = \sigma^2$ (los errores tienen varianza constante)

$H_1 : \text{Var}(\varepsilon_i) \neq \sigma^2$ (existe heterocedasticidad)

```
##  
## studentized Breusch-Pagan test  
##  
## data: mod_transformado2  
## BP = 44.762, df = 11, p-value = 5.343e-06
```

Se rechaza la hipótesis nula con $\alpha=0.05$, no existe homocedasticidad de los errores. Existe heterocedasticidad en el modelo

5.5.3. * 3. Prueba de autocorrelacion de los errores - Durbin Watson *

$H_0 : \rho = 0$ (no hay autocorrelación de los errores)

$H_1 : \rho \neq 0$ (los errores están correlacionados)

```
##  
## Durbin-Watson test  
##  
## data: mod_transformado2  
## DW = 2.0863, p-value = 0.8429  
## alternative hypothesis: true autocorrelation is greater than 0
```

NO se rechaza la hipótesis nula de que los errores son dependientes entre sí, se puede decir que los errores son independientes entre si (ortogonales)

5.5.4. * 4. Prueba de normalidad de los errores- Shapiro *

$H_0 : \varepsilon_i \sim N(0, \sigma^2)$ (los residuos son normalmente distribuidos)

$H_1 : \varepsilon_i \not\sim N(0, \sigma^2)$ (los residuos no son normales)

```
##
## Shapiro-Wilk normality test
##
## data: mod_transformado2$residuals
## W = 0.99643, p-value = 0.256
```

No se rechaza la hipótesis nula con un nivel de significancia de 0.05 de que el vector dado(residuales) tiene una distribución normal. Hay normalidad de los residuales

5.5.5. VIF - verificación de inflación de varianza por colinealidad

```
##              GVIF Df GVIF^(1/(2*Df))
## estrato      2.535046  5      1.097485
## log(area)    3.147193  1      1.774033
## banos        2.384351  1      1.544135
## garajes      2.760757  1      1.661552
## elevadores   1.200081  1      1.095482
## esCasa       1.067436  1      1.033168
## zona_de_lavanderia 1.024084  1      1.011970
```

Ningún VIF sobrepasa 5, No hay inflación de varianza significativa por colinealidad


De este modelo se puede concluir que re - escalar la variable área no fue útil para lograr homocedasticidad, se realizará un modelo ponderado, se le dará menor peso a las observaciones que generan la mayor varianza del error



5.6. Modelo con pesos


Nota: Se trabaja con estrato como variable categórica tras encontrar que esta transformación es favorable para el cumplimiento de los supuestos del modelo.

```
##
## Call:
## lm(formula = log(precio) ~ estrato + log(area) + banos + garajes +
##     elevadores + esCasa + zona_de_lavanderia, data = propiedades,
##     weights = 1/log(area)^2)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -0.108899 -0.025778 -0.001405  0.025477  0.144198
##
## Coefficients:
```

```
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)    16.687747   0.141120 118.252 < 2e-16 ***
## estrato3       0.260623   0.017352  15.020 < 2e-16 ***
## estrato4       0.501176   0.025458  19.687 < 2e-16 ***
## estrato5       0.550251   0.035860  15.345 < 2e-16 ***
## estrato6       0.612031   0.045869  13.343 < 2e-16 ***
## log(area)      0.493321   0.039264  12.564 < 2e-16 ***
## banos          0.107051   0.016211   6.604 9.62e-11 ***
## garajes        0.168043   0.018425   9.120 < 2e-16 ***
## elevadores     0.054661   0.009698   5.637 2.80e-08 ***
## esCasaSi       0.234387   0.058894   3.980 7.84e-05 ***
## zona_de_lavanderiaSi 0.056773   0.023457   2.420 0.0158 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03867 on 540 degrees of freedom
## Multiple R-squared:  0.8995, Adjusted R-squared:  0.8976
## F-statistic: 483.1 on 10 and 540 DF,  p-value: < 2.2e-16
```







Leverage

lm(log(precio) ~ estrato + log(area) + banos + garajes + elevadores + esCas ...

5.7. Comprobación de supuestos de modelo con pesos

5.7.1. * 1. Prueba de linealidad Y vs X - Test de Ramsey *

H_0 : El modelo está correctamente especificado (no hay variables omitidas ni no linealidad).

H_1 : El modelo está mal especificado (existen variables omitidas o no linealidad).

```
##
## RESET test
##
## data:  modelo_wls
## RESET = 0.91406, df1 = 2, df2 = 538, p-value = 0.4015
```

Se rechaza la hipótesis nula con $\alpha=0.05$, Hay linealidad , además no hay variables omitidas o comportamientos exponenciales no captados

5.7.2. * 2. Prueba de Breusch Pagan - Homocedasticidad *

H_0 : $\text{Var}(\varepsilon_i) = \sigma^2$ (los errores tienen varianza constante)

H_1 : $\text{Var}(\varepsilon_i) \neq \sigma^2$ (existe heterocedasticidad)

```
##
## studentized Breusch-Pagan test
##
## data: modelo_wls
## BP = 11.777, df = 10, p-value = 0.3003
```

NO se rechaza la hipótesis nula con $\alpha=0.05$, Existe homocedasticidad en el modelo completo

5.7.3. * 3. Prueba de autocorrelacion de los errores - Durbin Watson *

$$H_0 : \rho = 0 \quad (\text{no hay autocorrelación de los errores})$$

$$H_1 : \rho \neq 0 \quad (\text{los errores están correlacionados})$$

```
## lag Autocorrelation D-W Statistic p-value
## 1 -0.05197467 2.102149 0.23
## Alternative hypothesis: rho != 0
```

NO se rechaza la hipótesis nula de que los errores son dependientes entre sí, se puede decir que los errores son independientes entre si (ortogonales)

5.7.4. * 4. Prueba de normalidad de los errores- Shapiro *

$$H_0 : \varepsilon_i \sim N(0, \sigma^2) \quad (\text{los residuos son normalmente distribuidos})$$

$$H_1 : \varepsilon_i \not\sim N(0, \sigma^2) \quad (\text{los residuos no son normales})$$

```
##
## Shapiro-Wilk normality test
##
## data: modelo_wls$residuals
## W = 0.99731, p-value = 0.5134
```

NO se rechaza la hipótesis nula con un nivel de significancia de 0.05 de que el vector dado(residuales) tiene una distribución normal. Existe normalidad de los residuales

```
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 0.464606, Df = 1, p = 0.49548
```

5.7.5. VIF - verificación de inflación de varianza por colinealidad

	GVIF	Df	GVIF ^{1/(2*Df)}
estrato	2.438960	4	1.117894
log(area)	2.957770	1	1.719817
banos	2.336016	1	1.528403
garajes	2.707409	1	1.645421

```
## elevadores      1.210897  1      1.100407
## esCasa          1.068231  1      1.033553
## zona_de_lavanderia 1.021485  1      1.010686
```

Ningún VIF sobrepasa 5, **No hay inflación de varianza significativa por colinealidad**

EL modelo con pesos pasó todos los supuestos.

ESTE MODELO ES EL MEJOR QUE SE ENCONTRÓ, CUMPLE TODOS LOS SUPUESTOS Y TIENE BUEN AJUSTE

6. Parte 3: Exploración profunda del modelo final.

6.1. Confusión

Se observará cuáles variables existentes en el modelo son confusoras, se usará el criterio: “Si algun coeficiente cambia más del 10 %, es una variable confusora”:

```
##
## Call:
## lm(formula = log(precio) ~ estrato + log(area) + banos + garajes +
##     elevadores + esCasa + zona_de_lavanderia, data = propiedades,
##     weights = 1/log(area)^2)
##
## Coefficients:
##      (Intercept)      estrato3      estrato4
##      16.68775      0.26062      0.50118
##      estrato5      estrato6      log(area)
##      0.55025      0.61203      0.49332
##      banos      garajes      elevadores
##      0.10705      0.16804      0.05466
##      esCasaSi  zona_de_lavanderiaSi
##      0.23439      0.05677
```

6.1.0.1. Estrato Se muestra la tabla comparativa, que detalla el cambio en los B’s al quitar estrato.

```
##      Variable A..Sin.estrato B..Con.estrato
## (Intercept) (Intercept) 16.48967672 16.68774723
## log(area) log(area) 0.56037845 0.49332052
## banos banos 0.14655750 0.10705091
## garajes garajes 0.34475925 0.16804258
## elevadores elevadores 0.11968749 0.05466145
## esCasaSi esCasaSi 0.13529430 0.23438685
## zona_de_lavanderiaSi zona_de_lavanderiaSi 0.05376548 0.05677338
##      Cambio..B...A.
## (Intercept) 0.198070516
## log(area) -0.067057932
## banos -0.039506591
## garajes -0.176716664
```

```
## elevadores          -0.065026040
## esCasaSi            0.099092546
## zona_de_lavanderiaSi 0.003007896
```

Se observa un cambio en el intercepto y en garajes de mas de 10 %.

No se elimina ninguna variable porque todas son fundamentales para explicar el fenómeno.

6.1.0.2. log(area) Se muestra la tabla comparativa, que detalla el cambio en los B's al quitar log(area).

##	Variable	A..Sin.log.area.	B..Con.log.area.
## (Intercept)	(Intercept)	18.44373101	16.68774723
## estrato3	estrato3	0.26130990	0.26062256
## estrato4	estrato4	0.53068263	0.50117566
## estrato5	estrato5	0.57651634	0.55025071
## estrato6	estrato6	0.64128021	0.61203127
## banos	banos	0.22146377	0.10705091
## garajes	garajes	0.25756395	0.16804258
## elevadores	elevadores	0.04870465	0.05466145
## esCasaSi	esCasaSi	0.16764500	0.23438685
## zona_de_lavanderiaSi	zona_de_lavanderiaSi	0.05044887	0.05677338

##	Cambio..B...A.
## (Intercept)	-1.7559837753
## estrato3	-0.0006873447
## estrato4	-0.0295069737
## estrato5	-0.0262656304
## estrato6	-0.0292489408
## banos	-0.1144128599
## garajes	-0.0895213701
## elevadores	0.0059568002
## esCasaSi	0.0667418535
## zona_de_lavanderiaSi	0.0063245110

Se observa un cambio del 11 % en baños.

Por incompatibilidad con la naturaleza del fenómeno, no es posible eliminar logaritmo del área

6.1.0.3. Baños Se muestra la tabla comparativa, que detalla el cambio en los B's al quitar baños.

##	Variable	A..Sin.baños	B..Con.baños
## (Intercept)	(Intercept)	16.25647289	16.68774723
## estrato3	estrato3	0.27875532	0.26062256
## estrato4	estrato4	0.51482057	0.50117566
## estrato5	estrato5	0.57140704	0.55025071
## estrato6	estrato6	0.63150126	0.61203127
## log(area)	log(area)	0.63896803	0.49332052
## garajes	garajes	0.17369726	0.16804258
## elevadores	elevadores	0.05693123	0.05466145


```
## esCasaSi          esCasaSi    0.31165207    0.23438685
## zona_de_lavanderiaSi zona_de_lavanderiaSi    0.06252040    0.05677338
##                  Cambio..B...A.
## (Intercept)      0.431274338
## estrato3         -0.018132760
## estrato4         -0.013644917
## estrato5         -0.021156333
## estrato6         -0.019469986
## log(area)        -0.145647510
## garajes          -0.005654679
## elevadores       -0.002269772
## esCasaSi         -0.077265222
## zona_de_lavanderiaSi -0.005747025
```

En este caso se observa un cambio de 40 % en el intercepto (B0) y uno de 14 % en log(area).

No se tomara ninguna acción porque por un lado, quitar el intercepto puede hacer que se pierda interpretabilidad del modelo, y por el otro lado, los baños y los garajes es una variable que, en el contexto de negocio, es relevante en la construcción del precio de una vivienda.

Por otra parte, el área es fundamental para determinar el precio de una vivienda.

6.1.0.4. Garajes Se muestra la tabla comparativa, que detalla el cambio en los B's al quitar Garajes.

```
##                  Variable A..Sin.garajes B..Con.garajes
## (Intercept)      (Intercept)    16.14949215    16.68774723
## estrato3         estrato3        0.29147958    0.26062256
## estrato4         estrato4        0.59479151    0.50117566
## estrato5         estrato5        0.68496650    0.55025071
## estrato6         estrato6        0.76034499    0.61203127
## log(area)        log(area)       0.63179723    0.49332052
## banos            banos           0.11392207    0.10705091
## elevadores       elevadores      0.05363623    0.05466145
## esCasaSi         esCasaSi       0.27291212    0.23438685
## zona_de_lavanderiaSi zona_de_lavanderiaSi    0.06027878    0.05677338
##                  Cambio..B...A.
## (Intercept)      0.538255087
## estrato3         -0.030857026
## estrato4         -0.093615858
## estrato5         -0.134715786
## estrato6         -0.148313716
## log(area)        -0.138476715
## banos            -0.006871155
## elevadores       0.001025224
## esCasaSi         -0.038525276
## zona_de_lavanderiaSi -0.003505404
```

En este caso se observa un cambio de 50 % en el intercepto (B0), de 13 % aproximadamente en estrato5, estrato6 y log(area)

No se tomara ninguna acción porque: - por un lado, quitar el intercepto puede hacer que se pierda interpretabilidad del modelo.

- por otro lado, la cantidad de garajes es una variable que, en el contexto de negocio, es relevante en la construcción del precio de una vivienda.
- Además no es coherente remover solamente algunos estratos del modelo, se debe poder predecir con todos los estratos de acuerdo a la lógica de negocio. el área por su parte es fundamental para determinar el precio de una vivienda

Es decir, no se harán cambios en el modelo principal por la misma razón que en el análisis de baños

6.1.0.5. Elevadores Se muestra la tabla comparativa, que detalla el cambio en los B's al quitar Elevadores.

##	Variable	A..Sin.elevadores	B..Con.elevadores
## (Intercept)	(Intercept)	16.73425106	16.68774723
## estrato3	estrato3	0.28821947	0.26062256
## estrato4	estrato4	0.54269431	0.50117566
## estrato5	estrato5	0.59366364	0.55025071
## estrato6	estrato6	0.65524338	0.61203127
## log(area)	log(area)	0.48250054	0.49332052
## banos	banos	0.11028959	0.10705091
## garajes	garajes	0.16683871	0.16804258
## esCasaSi	esCasaSi	0.20379605	0.23438685
## zona_de_lavanderiaSi	zona_de_lavanderiaSi	0.06854513	0.05677338
##	Cambio..B...A.		
## (Intercept)		-0.046503824	
## estrato3		-0.027596913	
## estrato4		-0.041518657	
## estrato5		-0.043412930	
## estrato6		-0.043212105	
## log(area)		0.010819977	
## banos		-0.003238674	
## garajes		0.001203876	
## esCasaSi		0.030590797	
## zona_de_lavanderiaSi		-0.011771755	

En este caso se observa que la cantidad de elevadores no es una variable confusora de acuerdo al criterio empírico. "Si algún coeficiente cambia más del 10 %, es una variable confusora"

6.1.0.6. esCasa Se muestra la tabla comparativa, que detalla el cambio en los B's al quitar esCasa.

##	Variable	A..Sin.esCasa	B..Con.esCasa
## (Intercept)	(Intercept)	16.72963768	16.68774723
## estrato3	estrato3	0.25958004	0.26062256
## estrato4	estrato4	0.49403062	0.50117566
## estrato5	estrato5	0.53841460	0.55025071
## estrato6	estrato6	0.59939548	0.61203127
## log(area)	log(area)	0.47922618	0.49332052
## banos	banos	0.11986838	0.10705091

```
## garajes                garajes    0.17330206    0.16804258
## elevadores             elevadores  0.05110494    0.05466145
## zona_de_lavanderiaSi   zona_de_lavanderiaSi  0.05931915    0.05677338
##                         Cambio..B...A.
## (Intercept)            -0.041890445
## estrato3               0.001042514
## estrato4               0.007145033
## estrato5               0.011836112
## estrato6               0.012635792
## log(area)              0.014094341
## banos                  -0.012817471
## garajes                -0.005259473
## elevadores             0.003556510
## zona_de_lavanderiaSi   -0.002545771
```

En este caso se observa que la característica de ser una casa no es una variable confusora de acuerdo al criterio empírico. “Si algún coeficiente cambia más del 10 %, es una variable confusora” ##### zona_de_lavanderia Se muestra la tabla comparativa, que detalla el cambio en los B’s al quitar zona_de_lavanderia.

```
##                         Variable A..Sin.zona_de_lavanderia B..Con.zona_de_lavanderia
## (Intercept) (Intercept)          16.69786053          16.68774723
## estrato3     estrato3             0.25885592          0.26062256
## estrato4     estrato4             0.50270057          0.50117566
## estrato5     estrato5             0.54593653          0.55025071
## estrato6     estrato6             0.61157149          0.61203127
## log(area)    log(area)            0.49128119          0.49332052
## banos        banos                0.10850662          0.10705091
## garajes      garajes              0.16877330          0.16804258
## elevadores   elevadores           0.05675117          0.05466145
## esCasaSi     esCasaSi             0.23827401          0.23438685
##                         Cambio..B...A.
## (Intercept) -0.0101132997
## estrato3     0.0017666324
## estrato4     -0.0015249137
## estrato5     0.0043141818
## estrato6     0.0004597846
## log(area)    0.0020393274
## banos        -0.0014557100
## garajes      -0.0007307150
## elevadores   -0.0020897191
## esCasaSi     -0.0038871630
```

En este caso se observa que la característica de tener zona de lavandería no es una variable confusora de acuerdo al criterio empírico. “Si algún coeficiente cambia más del 10 %, es una variable confusora”

6.1.1. Resultados - confusión.

En conclusión , existen varias variables confusoras en el modelo:

- Baños: el coeficiente del intercepto (B_0) cambia 40 % aproximadamente.
- Garajes: el coeficiente del intercepto (B_0) cambia 50 % aproximadamente.
- Estrato: Cambios de mas de 10 % en coeficientes de varias variables.
- $\log(\text{area})$: Cambio de mas de 10 % en un coeficiente de una variable.


También se pudo observar que en todos las pruebas, era el intercepto el que más cambia.

NO se consideró eliminar alguna variable por su relevancia en el modelo, sin embargo será útil saber que estas variables son confusoras.

6.2. Interacción entre variables

Se usará el area y el precio como principales componentes de análisis, pues son las únicas variavles continuas del modelo

6.2.1. Relacion area vs precio de acuerdo a estratos



Pareciera que no existe interacción entre el estrato y el area para predecir la variable precio, no obstante se observa que la linea de estrato 6 difiere de las demás e incluso se cruza, mientras que las otras conservan paralelismo.

Obsérvese las proporciones:

```
##
##      1 o 2      3      4      5      6
## 0.33030853 0.36297641 0.19600726 0.07441016 0.03629764
```

Dado que todas las líneas son paralelas excepto estrato6, observemos cómo queda el modelo tras incluir aquella interacción


```
##
## Call:
## lm(formula = log(precio) ~ estrato + log(area) + banos + garajes +
##     log(area):I(estrato == 6) + elevadores + esCasa + zona_de_lavanderia,
##     data = propiedades, weights = 1/log(area)^2)
##
## Weighted Residuals:
##      Min      1Q   Median      3Q      Max
## -0.108871 -0.025060 -0.001207  0.024803  0.145533
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      16.581841    0.143529 115.529 < 2e-16 ***
## estrato3          0.257158    0.017229  14.926 < 2e-16 ***
## estrato4          0.492682    0.025362  19.426 < 2e-16 ***
## estrato5          0.538614    0.035715  15.081 < 2e-16 ***
## estrato6          2.165416    0.475247   4.556 6.44e-06 ***
## log(area)         0.521402    0.039842  13.087 < 2e-16 ***
## banos             0.105952    0.016070   6.593 1.03e-10 ***
## garajes           0.166788    0.018265   9.132 < 2e-16 ***
## elevadores        0.055137    0.009612   5.736 1.61e-08 ***
## esCasaSi          0.231992    0.058372   3.974 8.02e-05 ***
## zona_de_lavanderiaSi 0.049546    0.023351   2.122 0.03431 *
## log(area):I(estrato == 6)TRUE -0.359167    0.109381  -3.284 0.00109 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03832 on 539 degrees of freedom
## Multiple R-squared:  0.9014, Adjusted R-squared:  0.8994
## F-statistic: 448.1 on 11 and 539 DF, p-value: < 2.2e-16
```

La interacción resulta significativa, pero lleva a un problema de colinealidad:

```
##              GVIF Df GVIF^(1/(2*Df))
## estrato      351.274517  4      2.080683
## log(area)     3.100633  1      1.760861
## banos         2.337029  1      1.528734
## garajes       2.708594  1      1.645781
## elevadores    1.211171  1      1.100532
## esCasa        1.068398  1      1.033633
## zona_de_lavanderia 1.030643  1      1.015206
## log(area):I(estrato == 6) 157.998148  1      12.569731
```

Con este problema, esta interacción queda descartada, también teniendo en cuenta que su aporte al ajuste del modelo no es significativo.

6.2.2. Relación area vs precio de acuerdo a esCasa




Se observa una interacción con esCasa, sin embargo, como se puede ver; la mayoría de registros no son casas, lo que significa que el patrón real(poblacional) puede no está correctamente ni completamente representado. Esto porque casi no se observan puntos para los registros sin casa;

A continuación se observa la proporción de registros casa y no casa:

```
##
##           No           Si
## 0.98548094 0.01451906
```

No se tendrá en cuenta la interacción en el modelo por falta de confianza estadística para determinarla.

6.2.3. Relación area vs precio de acuerdo a zona_de_lavanderia.



Se

aprecia interacción, sin embargo sucede lo mismo que en el caso anterior :

```
##  
##           No           Si  
## 0.9092559 0.0907441
```

6.3. Apalancamiento y análisis de observaciones influyentes

6.3.1. Apalancamiento

No se mostrará el listado de observaciones con apalancamiento, pues son bastantes y resulta dispendioso.

A continuación se muestra el apalancamiento en el conjunto de datos:

```
## # A tibble: 2 x 3  
##   tipo          n porcentaje  
##   <chr>      <int>      <dbl>  
## 1 Alto leverage    50      9.07  
## 2 Bajo leverage   501     90.9
```


el 9 % del conjunto de datos presenta apalancamiento, es decir: posee características alejadas del promedio de todos los registros (X).

6.3.2. Influencia

Ahora se verificará la influencia.

6.3.2.1. Distancia de cook


```
## # A tibble: 551 x 4
##   obs   cook flag_soft flag_hard
##   <int> <dbl> <lgl>    <lgl>
## 1   373 0.198  TRUE     FALSE
## 2   485 0.141  TRUE     FALSE
## 3   474 0.0966 TRUE     FALSE
## 4   486 0.0889 TRUE     FALSE
## 5   447 0.0580 TRUE     FALSE
## 6     5 0.0489 TRUE     FALSE
## 7   309 0.0446 TRUE     FALSE
## 8   383 0.0446 TRUE     FALSE
## 9   354 0.0350 TRUE     FALSE
## 10  479 0.0167 TRUE     FALSE
## # i 541 more rows
```



Existen registros influyentes con el umbral suave.

6.3.2.2. DF FITS :)


DFFITS por observación
Umbral $\pm 2 \cdot \sqrt{p/n} = \pm 0.2826$



Existen observaciones influyentes

6.3.2.3. COVRATIO

```
## 2 5 14 17 27 30 98 99 101 108 115 117 152 183 202 204 230 241 250 263
## 2 5 14 17 27 30 98 99 101 108 115 117 152 183 202 204 230 241 250 263
## 284 299 302 309 352 354 373 376 392 438 443 447 467 474 478 479 481 486 488 500
## 284 299 302 309 352 354 373 376 392 438 443 447 467 474 478 479 481 486 488 500
## 510 511 542
## 510 511 542
```



Existen observaciones influyentes

6.3.2.4. Coincidencias ¿Cuales son las observaciones en las cuales todos los métodos coinciden?

```
## # A tibble: 14 x 1
##   obs
##   <int>
## 1   373
## 2   474
## 3   486
## 4   447
## 5     5
## 6   309
## 7   354
## 8   479
## 9    98
## 10  478
## 11  443
## 12  250
## 13   14
## 14  117
```

Existen 14 registros problematicos que influyen significativamente.

```
## # A tibble: 14 x 6
```

```
##      precio  area estrato banos garajes esCasa
##      <dbl> <dbl> <fct>   <int>   <int> <fct>
##  1 145800000    41 3         1       0 Si
##  2 450000000    45 3         4       1 Si
##  3 320000000    45 3         2       0 Si
##  4 450000000    72 1 o 2     4       1 Si
##  5 387000000   105 4         2       1 Si
##  6 355000000    74 3         3       2 Si
##  7 250000000    35 3         1       0 No
##  8 490000000   126 1 o 2     3       1 Si
##  9 174000000    59 3         2       0 No
## 10 270000000    38 3         1       0 No
## 11 440000000    59 3         2       1 No
## 12 167613000    62 1 o 2     1       0 Si
## 13 200000000    38 1 o 2     1       0 No
## 14 142340000    49 3         1       1 No
```

Estas observaciones son raras (no usuales), aunque son posibles en el estudio de este fenomeno, por dar algunos ejemplos

- Observaciones 1 y 2: es raro que dos viviendas estrato 2 de similar area tengan una diferencia de 300 Millones de pesos, el mas costoso tiene 1 garaje y dos baños mas que el otro.
- Observación 7: 250 Millones es demasiado para un apartamento de tan sólo 35m2 que está en un estrato 2.
- Observacion 9: No es usual encontrar viviendas de 490 Millones en el estrato 1 .

Estas observaciones NO seran excluidas del modelo, si bien son no - usuales, son propias del fenomeno, es aceptable que esto suceda en la vida real (podría suceder).

6.4. *Selección de variables usando criterios de informacion*

Se usarán todas las variables del modelo actual (7), se podrá determinar si existen modelos mas pequeños que este que puedan ofrecer un ajuste similar. ### Forward Aplicacion de la técnica stepwise:

```
## Start:  AIC=-2327.91
## log(precio) ~ 1
##
##      Df Sum of Sq    RSS    AIC
## + estrato      4   5.6917 2.3385 -2999.7
## + garajes      1   5.2174 2.8129 -2903.9
## + log(area)     1   5.1507 2.8796 -2891.0
## + banos        1   4.0730 3.9573 -2715.8
## + elevadores   1   1.1005 6.9298 -2407.1
## + zona_de_lavanderia 1   0.0715 7.9588 -2330.8
## + esCasa       1   0.0629 7.9674 -2330.2
## <none>                8.0303 -2327.9
##
```

```

## Step: AIC=-2999.68
## log(precio) ~ estrato
##
##
## Df Sum of Sq RSS AIC
## + log(area) 1 1.21529 1.1232 -3401.7
## + banos 1 0.89539 1.4431 -3263.6
## + garajes 1 0.78613 1.5524 -3223.4
## + esCasa 1 0.09966 2.2389 -3021.7
## + elevadores 1 0.02438 2.3141 -3003.5
## + zona_de_lavanderia 1 0.02124 2.3173 -3002.7
## <none> 2.3385 -2999.7
##
## Step: AIC=-3401.74
## log(precio) ~ estrato + log(area)
##
##
## Df Sum of Sq RSS AIC
## + garajes 1 0.146338 0.97689 -3476.6
## + banos 1 0.105155 1.01807 -3453.9
## + esCasa 1 0.050566 1.07266 -3425.1
## + elevadores 1 0.045968 1.07726 -3422.8
## + zona_de_lavanderia 1 0.018773 1.10445 -3409.0
## <none> 1.12323 -3401.7
##
## Step: AIC=-3476.65
## log(precio) ~ estrato + log(area) + garajes
##
##
## Df Sum of Sq RSS AIC
## + banos 1 0.090541 0.88635 -3528.2
## + elevadores 1 0.048553 0.92834 -3502.7
## + esCasa 1 0.037353 0.93954 -3496.1
## + zona_de_lavanderia 1 0.016770 0.96012 -3484.2
## <none> 0.97689 -3476.6
##
## Step: AIC=-3528.24
## log(precio) ~ estrato + log(area) + garajes + banos
##
##
## Df Sum of Sq RSS AIC
## + elevadores 1 0.045774 0.84057 -3555.5
## + esCasa 1 0.018653 0.86769 -3538.0
## + zona_de_lavanderia 1 0.013466 0.87288 -3534.7
## <none> 0.88635 -3528.2
##
## Step: AIC=-3555.46
## log(precio) ~ estrato + log(area) + garajes + banos + elevadores
##
##
## Df Sum of Sq RSS AIC
## + esCasa 1 0.0244901 0.81608 -3569.8
## + zona_de_lavanderia 1 0.0095682 0.83101 -3559.8
## <none> 0.84057 -3555.5
##

```

```

## Step: AIC=-3569.75
## log(precio) ~ estrato + log(area) + garajes + banos + elevadores +
##     esCasa
##
##              Df Sum of Sq    RSS    AIC
## + zona_de_lavanderia  1  0.008758 0.80733 -3573.7
## <none>                  0.81608 -3569.8
##
## Step: AIC=-3573.7
## log(precio) ~ estrato + log(area) + garajes + banos + elevadores +
##     esCasa + zona_de_lavanderia

##
## Call:
## lm(formula = log(precio) ~ estrato + log(area) + garajes + banos +
##     elevadores + esCasa + zona_de_lavanderia, data = propiedades,
##     weights = 1/log(area)^2)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -0.108899 -0.025778 -0.001405  0.025477  0.144198
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    16.687747   0.141120 118.252 < 2e-16 ***
## estrato3        0.260623   0.017352  15.020 < 2e-16 ***
## estrato4        0.501176   0.025458  19.687 < 2e-16 ***
## estrato5        0.550251   0.035860  15.345 < 2e-16 ***
## estrato6        0.612031   0.045869  13.343 < 2e-16 ***
## log(area)       0.493321   0.039264  12.564 < 2e-16 ***
## garajes         0.168043   0.018425   9.120 < 2e-16 ***
## banos           0.107051   0.016211   6.604 9.62e-11 ***
## elevadores      0.054661   0.009698   5.637 2.80e-08 ***
## esCasaSi        0.234387   0.058894   3.980 7.84e-05 ***
## zona_de_lavanderiaSi 0.056773  0.023457   2.420  0.0158 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03867 on 540 degrees of freedom
## Multiple R-squared:  0.8995, Adjusted R-squared:  0.8976
## F-statistic: 483.1 on 10 and 540 DF, p-value: < 2.2e-16

```

Se obtiene el mismo modelo actual. ### Backwards

```

## Start: AIC=-3573.7
## log(precio) ~ estrato + log(area) + banos + garajes + elevadores +
##     esCasa + zona_de_lavanderia
##
##              Df Sum of Sq    RSS    AIC

```

```
## <none>                                0.80733 -3573.7
## - zona_de_lavanderia  1    0.00876 0.81608 -3569.8
## - esCasa              1    0.02368 0.83101 -3559.8
## - elevadores          1    0.04750 0.85483 -3544.2
## - banos               1    0.06520 0.87252 -3532.9
## - garajes             1    0.12436 0.93168 -3496.8
## - log(area)           1    0.23601 1.04334 -3434.4
## - estrato             4    0.67374 1.48106 -3247.4
```

Se obtiene el mismo modelo actual

6.4.1. Híbrido

```
## Start:  AIC=-2891.01
## log(precio) ~ log(area)
##
##           Df Sum of Sq    RSS    AIC
## + estrato    4     1.7563 1.1232 -3401.7
## + garajes    1     0.9493 1.9302 -3109.4
## + elevadores  1     0.4521 2.4274 -2983.1
## + banos      1     0.2782 2.6014 -2945.0
## + zona_de_lavanderia 1     0.0344 2.8452 -2895.6
## + esCasa     1     0.0199 2.8597 -2892.8
## <none>              2.8796 -2891.0
## - log(area)      1     5.1507 8.0303 -2327.9
##
## Step:  AIC=-3401.74
## log(precio) ~ log(area) + estrato
##
##           Df Sum of Sq    RSS    AIC
## + garajes    1     0.14634 0.97689 -3476.6
## + banos      1     0.10515 1.01807 -3453.9
## + esCasa     1     0.05057 1.07266 -3425.1
## + elevadores  1     0.04597 1.07726 -3422.8
## + zona_de_lavanderia 1     0.01877 1.10445 -3409.0
## <none>              1.12323 -3401.7
## - log(area)      1     1.21529 2.33852 -2999.7
## - estrato       4     1.75635 2.87957 -2891.0
##
## Step:  AIC=-3476.65
## log(precio) ~ log(area) + estrato + garajes
##
##           Df Sum of Sq    RSS    AIC
## + banos      1     0.09054 0.88635 -3528.2
## + elevadores  1     0.04855 0.92834 -3502.7
## + esCasa     1     0.03735 0.93954 -3496.1
## + zona_de_lavanderia 1     0.01677 0.96012 -3484.2
## <none>              0.97689 -3476.6
## - garajes     1     0.14634 1.12323 -3401.7
```

```

## - log(area)          1  0.57550 1.55239 -3223.4
## - estrato            4  0.95335 1.93024 -3109.4
##
## Step:  AIC=-3528.24
## log(precio) ~ log(area) + estrato + garajes + banos
##
##              Df Sum of Sq    RSS    AIC
## + elevadores    1  0.04577 0.84057 -3555.5
## + esCasa        1  0.01865 0.86769 -3538.0
## + zona_de_lavanderia 1  0.01347 0.87288 -3534.7
## <none>                0.88635 -3528.2
## - banos          1  0.09054 0.97689 -3476.6
## - garajes        1  0.13172 1.01807 -3453.9
## - log(area)      1  0.21422 1.10057 -3411.0
## - estrato        4  0.86903 1.75538 -3159.7
##
## Step:  AIC=-3555.46
## log(precio) ~ log(area) + estrato + garajes + banos + elevadores
##
##              Df Sum of Sq    RSS    AIC
## + esCasa        1  0.02449 0.81608 -3569.8
## + zona_de_lavanderia 1  0.00957 0.83101 -3559.8
## <none>                0.84057 -3555.5
## - elevadores    1  0.04577 0.88635 -3528.2
## - banos          1  0.08776 0.92834 -3502.7
## - garajes        1  0.13431 0.97488 -3475.8
## - log(area)      1  0.22245 1.06302 -3428.1
## - estrato        4  0.65684 1.49741 -3245.3
##
## Step:  AIC=-3569.75
## log(precio) ~ log(area) + estrato + garajes + banos + elevadores +
##      esCasa
##
##              Df Sum of Sq    RSS    AIC
## + zona_de_lavanderia 1  0.00876 0.80733 -3573.7
## <none>                0.81608 -3569.8
## - esCasa          1  0.02449 0.84057 -3555.5
## - elevadores      1  0.05161 0.86769 -3538.0
## - banos           1  0.06707 0.88316 -3528.2
## - garajes         1  0.12547 0.94156 -3492.9
## - log(area)       1  0.23417 1.05025 -3432.7
## - estrato         4  0.67290 1.48899 -3246.4
##
## Step:  AIC=-3573.7
## log(precio) ~ log(area) + estrato + garajes + banos + elevadores +
##      esCasa + zona_de_lavanderia
##
##              Df Sum of Sq    RSS    AIC
## <none>                0.80733 -3573.7
## - zona_de_lavanderia 1  0.00876 0.81608 -3569.8

```

```
## - esCasa          1    0.02368 0.83101 -3559.8
## - elevadores      1    0.04750 0.85483 -3544.2
## - banos           1    0.06520 0.87252 -3532.9
## - garajes         1    0.12436 0.93168 -3496.8
## - log(area)       1    0.23601 1.04334 -3434.4
## - estrato         4    0.67374 1.48106 -3247.4
```

Se ha obtenido el mismo modelo.

En los tres métodos de selección se determina que, dentro del espectro de variables propuesto, es el que mejor AIC tiene.

Ahora se intentará probar otro modelo, ampliando el espectro de variables pero manteniendpo la estructura de pesos

```
## Start:  AIC=-2891.01
## log(precio) ~ log(area)
##
##           Df Sum of Sq    RSS    AIC
## + estrato      4      1.7563 1.1232 -3401.7
## + garajes      1      0.9493 1.9302 -3109.4
## + administracion 1      0.7808 2.0988 -3063.3
## + elevadores   1      0.4521 2.4274 -2983.1
## + habitaciones 1      0.4444 2.4352 -2981.4
## + deposito     1      0.2976 2.5819 -2949.1
## + banos        1      0.2782 2.6014 -2945.0
## + area         1      0.0467 2.8328 -2898.0
## + tipo_de_inmueble 2      0.0485 2.8311 -2896.4
## + porteria     1      0.0371 2.8425 -2896.2
## + zona_de_lavanderia 1      0.0344 2.8452 -2895.6
## + esCasa       1      0.0199 2.8597 -2892.8
## + gas          1      0.0107 2.8688 -2891.1
## <none>                2.8796 -2891.0
## + remodelado   1      0.0045 2.8751 -2889.9
## + parqueadero  1      0.0009 2.8786 -2889.2
## + antiguedad   1      0.0002 2.8793 -2889.1
## - log(area)    1      5.1507 8.0303 -2327.9
##
## Step:  AIC=-3401.74
## log(precio) ~ log(area) + estrato
##
##           Df Sum of Sq    RSS    AIC
## + garajes      1      0.14634 0.97689 -3476.6
## + banos        1      0.10515 1.01807 -3453.9
## + administracion 1      0.08234 1.04089 -3441.7
## + esCasa       1      0.05057 1.07266 -3425.1
## + tipo_de_inmueble 2      0.05092 1.07231 -3423.3
## + elevadores   1      0.04597 1.07726 -3422.8
## + deposito     1      0.03548 1.08774 -3417.4
## + antiguedad   1      0.02562 1.09761 -3412.4
## + area         1      0.02462 1.09861 -3411.9
```



```
## + zona_de_lavanderia 1 0.01877 1.10445 -3409.0
## + porteria 1 0.01165 1.11158 -3405.5
## <none> 1.12323 -3401.7
## + habitaciones 1 0.00350 1.11973 -3401.5
## + parqueadero 1 0.00086 1.12236 -3400.2
## + gas 1 0.00033 1.12289 -3399.9
## + remodelado 1 0.00016 1.12307 -3399.8
## - log(area) 1 1.21529 2.33852 -2999.7
## - estrato 4 1.75635 2.87957 -2891.0
##
```

Step: AIC=-3476.65

log(precio) ~ log(area) + estrato + garajes

```
##
##          Df Sum of Sq    RSS    AIC
## + banos 1 0.09054 0.88635 -3528.2
## + elevadores 1 0.04855 0.92834 -3502.7
## + administracion 1 0.04569 0.93120 -3501.0
## + esCasa 1 0.03735 0.93954 -3496.1
## + tipo_de_inmueble 2 0.03926 0.93762 -3495.3
## + antiguedad 1 0.02473 0.95216 -3488.8
## + area 1 0.01763 0.95926 -3484.7
## + zona_de_lavanderia 1 0.01677 0.96012 -3484.2
## + deposito 1 0.01367 0.96322 -3482.4
## + porteria 1 0.00747 0.96941 -3478.9
## <none> 0.97689 -3476.6
## + gas 1 0.00051 0.97637 -3474.9
## + parqueadero 1 0.00030 0.97659 -3474.8
## + remodelado 1 0.00028 0.97660 -3474.8
## + habitaciones 1 0.00017 0.97672 -3474.7
## - garajes 1 0.14634 1.12323 -3401.7
## - log(area) 1 0.57550 1.55239 -3223.4
## - estrato 4 0.95335 1.93024 -3109.4
##
```

Step: AIC=-3528.24

log(precio) ~ log(area) + estrato + garajes + banos

```
##
##          Df Sum of Sq    RSS    AIC
## + administracion 1 0.04838 0.83797 -3557.2
## + elevadores 1 0.04577 0.84057 -3555.5
## + area 1 0.02242 0.86393 -3540.4
## + antiguedad 1 0.02033 0.86602 -3539.0
## + esCasa 1 0.01865 0.86769 -3538.0
## + tipo_de_inmueble 2 0.02104 0.86531 -3537.5
## + deposito 1 0.01360 0.87275 -3534.8
## + zona_de_lavanderia 1 0.01347 0.87288 -3534.7
## + habitaciones 1 0.00570 0.88065 -3529.8
## + porteria 1 0.00400 0.88235 -3528.7
## <none> 0.88635 -3528.2
## + remodelado 1 0.00030 0.88605 -3526.4
## + parqueadero 1 0.00029 0.88606 -3526.4
```

```

## + gas                1    0.00013 0.88622 -3526.3
## - banos              1    0.09054 0.97689 -3476.6
## - garajes            1    0.13172 1.01807 -3453.9
## - log(area)          1    0.21422 1.10057 -3411.0
## - estrato            4    0.86903 1.75538 -3159.7
##
## Step:  AIC=-3557.17
## log(precio) ~ log(area) + estrato + garajes + banos + administracion
##
##              Df Sum of Sq    RSS    AIC
## + elevadores    1    0.03397 0.80400 -3578.0
## + tipo_de_inmueble  2    0.03148 0.80649 -3574.3
## + esCasa        1    0.02665 0.81132 -3573.0
## + zona_de_lavanderia 1    0.01793 0.82004 -3567.1
## + antiguedad     1    0.01779 0.82018 -3567.0
## + deposito      1    0.01040 0.82757 -3562.0
## + porteria      1    0.00812 0.82985 -3560.5
## + area          1    0.00385 0.83412 -3557.7
## <none>                0.83797 -3557.2
## + habitaciones   1    0.00078 0.83719 -3555.7
## + gas            1    0.00042 0.83755 -3555.4
## + parqueadero    1    0.00023 0.83774 -3555.3
## + remodelado     1    0.00000 0.83797 -3555.2
## - administracion  1    0.04838 0.88635 -3528.2
## - banos          1    0.09323 0.93120 -3501.0
## - garajes        1    0.09640 0.93437 -3499.2
## - log(area)      1    0.14883 0.98680 -3469.1
## - estrato        4    0.66056 1.49853 -3244.9
##
## Step:  AIC=-3577.97
## log(precio) ~ log(area) + estrato + garajes + banos + administracion +
##      elevadores
##
##              Df Sum of Sq    RSS    AIC
## + tipo_de_inmueble  2    0.04156 0.76243 -3603.2
## + esCasa          1    0.03151 0.77249 -3598.0
## + zona_de_lavanderia 1    0.01348 0.79052 -3585.3
## + porteria        1    0.01069 0.79331 -3583.3
## + deposito        1    0.00683 0.79717 -3580.7
## + area            1    0.00401 0.79998 -3578.7
## <none>                0.80400 -3578.0
## + antiguedad      1    0.00283 0.80117 -3577.9
## + habitaciones    1    0.00079 0.80321 -3576.5
## + parqueadero     1    0.00078 0.80322 -3576.5
## + gas             1    0.00031 0.80369 -3576.2
## + remodelado      1    0.00024 0.80376 -3576.1
## - elevadores      1    0.03397 0.83797 -3557.2
## - administracion  1    0.03658 0.84057 -3555.5
## - banos           1    0.09042 0.89442 -3521.2
## - garajes         1    0.10154 0.90554 -3514.4

```

```

## - log(area)          1  0.15957 0.96356 -3480.2
## - estrato            4  0.52513 1.32913 -3309.0
##
## Step: AIC=-3603.22
## log(precio) ~ log(area) + estrato + garajes + banos + administracion +
##     elevadores + tipo_de_inmueble
##
##
##      Df Sum of Sq    RSS    AIC
## + zona_de_lavanderia  1  0.01190 0.75053 -3609.9
## + deposito           1  0.00718 0.75525 -3606.4
## + porteria           1  0.00675 0.75568 -3606.1
## + antiguedad         1  0.00634 0.75609 -3605.8
## + habitaciones       1  0.00306 0.75937 -3603.4
## <none>                0.76243 -3603.2
## + area               1  0.00169 0.76074 -3602.4
## + gas                1  0.00045 0.76198 -3601.5
## + remodelado         1  0.00021 0.76222 -3601.4
## + parqueadero        1  0.00000 0.76243 -3601.2
## - tipo_de_inmueble    2  0.04156 0.80400 -3578.0
## - elevadores          1  0.04406 0.80649 -3574.3
## - administracion      1  0.04621 0.80864 -3572.8
## - banos               1  0.06800 0.83044 -3558.1
## - garajes             1  0.09352 0.85595 -3541.5
## - log(area)           1  0.14942 0.91185 -3506.6
## - estrato             4  0.53244 1.29488 -3319.4
##
## Step: AIC=-3609.89
## log(precio) ~ log(area) + estrato + garajes + banos + administracion +
##     elevadores + tipo_de_inmueble + zona_de_lavanderia
##
##
##      Df Sum of Sq    RSS    AIC
## + porteria           1  0.00770 0.74283 -3613.6
## + deposito           1  0.00630 0.74423 -3612.5
## + antiguedad         1  0.00556 0.74497 -3612.0
## <none>                0.75053 -3609.9
## + habitaciones       1  0.00238 0.74815 -3609.6
## + area               1  0.00118 0.74935 -3608.8
## + gas                1  0.00008 0.75045 -3608.0
## + parqueadero        1  0.00006 0.75048 -3607.9
## + remodelado         1  0.00004 0.75049 -3607.9
## - zona_de_lavanderia  1  0.01190 0.76243 -3603.2
## - tipo_de_inmueble    2  0.03999 0.79052 -3585.3
## - elevadores          1  0.03890 0.78943 -3584.0
## - administracion      1  0.05005 0.80058 -3576.3
## - banos               1  0.06579 0.81632 -3565.6
## - garajes             1  0.09088 0.84141 -3548.9
## - log(area)           1  0.14965 0.90018 -3511.7
## - estrato             4  0.52894 1.27947 -3324.0
##
## Step: AIC=-3613.57

```

```

## log(precio) ~ log(area) + estrato + garajes + banos + administracion +
##     elevadores + tipo_de_inmueble + zona_de_lavanderia + porteria
##
##
##      Df Sum of Sq    RSS    AIC
## + antiguedad      1  0.00651 0.73632 -3616.4
## + deposito        1  0.00635 0.73647 -3616.3
## <none>                                0.74283 -3613.6
## + habitaciones    1  0.00230 0.74052 -3613.3
## + area             1  0.00106 0.74177 -3612.4
## + gas              1  0.00014 0.74269 -3611.7
## + parqueadero      1  0.00006 0.74277 -3611.6
## + remodelado       1  0.00000 0.74282 -3611.6
## - porteria         1  0.00770 0.75053 -3609.9
## - zona_de_lavanderia 1  0.01286 0.75568 -3606.1
## - tipo_de_inmueble 2  0.03575 0.77858 -3591.7
## - elevadores       1  0.04097 0.78379 -3586.0
## - administracion   1  0.05355 0.79638 -3577.2
## - banos            1  0.06366 0.80649 -3570.3
## - garajes          1  0.08771 0.83053 -3554.1
## - log(area)        1  0.15032 0.89315 -3514.0
## - estrato          4  0.51207 1.25490 -3332.7
##
## Step:  AIC=-3616.42
## log(precio) ~ log(area) + estrato + garajes + banos + administracion +
##     elevadores + tipo_de_inmueble + zona_de_lavanderia + porteria +
##     antiguedad
##
##
##      Df Sum of Sq    RSS    AIC
## + deposito        1  0.00520 0.73112 -3618.3
## <none>                                0.73632 -3616.4
## + habitaciones    1  0.00174 0.73458 -3615.7
## + area             1  0.00076 0.73555 -3615.0
## + remodelado       1  0.00003 0.73629 -3614.4
## + gas              1  0.00003 0.73629 -3614.4
## + parqueadero      1  0.00002 0.73629 -3614.4
## - antiguedad       1  0.00651 0.74283 -3613.6
## - porteria         1  0.00865 0.74497 -3612.0
## - zona_de_lavanderia 1  0.01204 0.74836 -3609.5
## - elevadores       1  0.02080 0.75712 -3603.1
## - tipo_de_inmueble 2  0.03889 0.77521 -3592.1
## - administracion   1  0.05518 0.79150 -3578.6
## - banos            1  0.06040 0.79672 -3575.0
## - garajes          1  0.08598 0.82230 -3557.6
## - log(area)        1  0.15678 0.89310 -3512.1
## - estrato          4  0.50803 1.24435 -3335.3
##
## Step:  AIC=-3618.33
## log(precio) ~ log(area) + estrato + garajes + banos + administracion +
##     elevadores + tipo_de_inmueble + zona_de_lavanderia + porteria +
##     antiguedad + deposito

```

```

##
##              Df Sum of Sq      RSS      AIC
## <none>                0.73112 -3618.3
## + habitaciones      1   0.00159 0.72953 -3617.5
## + area               1   0.00052 0.73059 -3616.7
## - deposito          1   0.00520 0.73632 -3616.4
## + parqueadero       1   0.00012 0.73100 -3616.4
## + gas                1   0.00004 0.73107 -3616.4
## + remodelado        1   0.00002 0.73110 -3616.3
## - antigüedad        1   0.00536 0.73647 -3616.3
## - porteria          1   0.00862 0.73974 -3613.9
## - zona_de_lavanderia 1   0.01130 0.74242 -3611.9
## - elevadores        1   0.01983 0.75094 -3605.6
## - tipo_de_inmueble   2   0.03887 0.76998 -3593.8
## - administracion     1   0.05302 0.78414 -3581.8
## - banos              1   0.06060 0.79172 -3576.5
## - garajes            1   0.07603 0.80714 -3565.8
## - log(area)          1   0.15302 0.88414 -3515.6
## - estrato            4   0.49920 1.23032 -3339.6

##
## Call:
## lm(formula = log(precio) ~ log(area) + estrato + garajes + banos +
##     administracion + elevadores + tipo_de_inmueble + zona_de_lavanderia +
##     porteria + antigüedad + deposito, data = propiedades, weights = 1/log(area)^2)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -0.110717 -0.026087  0.000273  0.025729  0.135210
##
## Coefficients:
##
##              Estimate Std. Error t value
## (Intercept)      1.698e+01  1.452e-01 116.937
## log(area)         4.300e-01  4.063e-02  10.582
## estrato3          2.549e-01  1.708e-02  14.926
## estrato4          4.729e-01  2.591e-02  18.250
## estrato5          4.692e-01  3.866e-02  12.138
## estrato6          5.015e-01  4.901e-02  10.232
## garajes           1.373e-01  1.841e-02   7.459
## banos             1.036e-01  1.556e-02   6.659
## administracion    3.828e-07  6.145e-08   6.229
## elevadores        4.058e-02  1.065e-02   3.809
## tipo_de_inmuebleCasa 2.717e-01  5.798e-02   4.686
## tipo_de_inmueblecasa con conjunto cerrado 8.710e-02  3.145e-02   2.770
## zona_de_lavanderiaSi 6.503e-02  2.261e-02   2.876
## porteriaSi        -6.443e-02  2.565e-02  -2.512
## antigüedad        -1.652e-03  8.342e-04  -1.980
## depositoSi        4.015e-02  2.058e-02   1.951
##
##              Pr(>|t|)
## (Intercept)      < 2e-16 ***

```

```
## log(area) < 2e-16 ***
## estrato3 < 2e-16 ***
## estrato4 < 2e-16 ***
## estrato5 < 2e-16 ***
## estrato6 < 2e-16 ***
## garajes 3.55e-13 ***
## banos 6.84e-11 ***
## administracion 9.51e-10 ***
## elevadores 0.000156 ***
## tipo_de_inmuebleCasa 3.54e-06 ***
## tipo_de_inmueblecasa con conjunto cerrado 0.005803 **
## zona_de_lavanderiaSi 0.004189 **
## porteriaSi 0.012313 *
## antiguedad 0.048218 *
## depositoSi 0.051583 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03697 on 535 degrees of freedom
## Multiple R-squared:  0.909, Adjusted R-squared:  0.9064
## F-statistic: 356.1 on 15 and 535 DF, p-value: < 2.2e-16
```

Este nuevo modelo tiene 11 predictores, aunque depositoSI tiene pvalue >0.05

este modelo es interesante, mejora el ajuste en aproximadamente 0.01, sin embargo , con esta nueva combinación de variables el modelo incumple un supuesto.

```
##
## RESET test
##
## data: m_step_aic
## RESET = 6.4936, df1 = 2, df2 = 533, p-value = 0.001636
```

Se rechaza la hipótesis nula con $\alpha=0.05$, Hay no - linealidad o variables omitidas o comportamientos exponenciales no captados

Este modelo será descartado y se continuará con el actual, nótese que AIC_both=-3618.33 y AIC_actual=-3573, afortunadamente la diferencia no es demasiada

6.5. Validación y pronósticos del modelo.

Para evitar data-leakage, se partira desde 0: Se leerán los datos de nuevo, se partiran en conjuntos de entrenamiento y pruebas, se realizarán las transformaciones necesarias y se procederá al entrenamiento y la validación del modelo

```
##
## Call:
## lm(formula = log(precio) ~ estrato + log(area) + banos + garajes +
##     elevadores + esCasa + zona_de_lavanderia, data = train, weights = 1/log(area)^2)
##
```

```
## Weighted Residuals:
##      Min      1Q      Median      3Q      Max
## -0.105882 -0.025214 -0.002228  0.025332  0.143548
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    16.70884    0.16236 102.911 < 2e-16 ***
## estrato3        0.25916    0.02047  12.661 < 2e-16 ***
## estrato4        0.49290    0.02983  16.523 < 2e-16 ***
## estrato5        0.56199    0.04126  13.622 < 2e-16 ***
## estrato6        0.63552    0.05309  11.971 < 2e-16 ***
## log(area)       0.48836    0.04515  10.816 < 2e-16 ***
## banos           0.10638    0.01898   5.604 3.75e-08 ***
## garajes         0.17043    0.02132   7.994 1.22e-14 ***
## elevadores      0.05634    0.01132   4.977 9.37e-07 ***
## esCasaSi        0.23343    0.06137   3.804 0.000163 ***
## zona_de_lavanderiaSi 0.06959    0.02905   2.395 0.017038 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03993 on 430 degrees of freedom
## Multiple R-squared:  0.8941, Adjusted R-squared:  0.8916
## F-statistic: 363 on 10 and 430 DF, p-value: < 2.2e-16

##              MAE              MSE              RMSE      R2      MAPE
## Train_Log      0.1259              0.0251      0.1585 0.9015  0.6529
## Test_Log       0.1112              0.0182      0.1351 0.9238  0.5798
## Train_Nivel 34543855.1659 2902719684997788.0000 53876893.7950 0.8756 12.6618
## Test_Nivel  27921629.1585 1538187070091655.7500 39219728.0726 0.9092 11.3043
```

Las metricas del modelo fueron similares en conjuntos de entrenamiento y prueba tanto en log-log como en level-level.

No existe evidencia de sub o sobre ajuste. El modelo tiene métricas aceptables para la predicción de precios. Se equivoca en promedio un 12 % para predecir el precio.

7. Interpretacion final

Finalmente se obtuvo que las variables predictoras logran explicar un 89.95 % de la varianza del precio, la formula.

$$w_i = \frac{1}{[\log(\text{area}_i)]^2}$$

$$\begin{aligned} \log(\text{precio}_i) = & 16,6877 + 0,2606 \text{ estrato3}_i + 0,5012 \text{ estrato4}_i + 0,5503 \text{ estrato5}_i \\ & + 0,6120 \text{ estrato6}_i + 0,4933 \log(\text{area}_i) + 0,1071 \text{ banos}_i \\ & + 0,1680 \text{ garajes}_i + 0,0547 \text{ elevadores}_i + 0,2344 \text{ esCasaSi}_i \\ & + 0,0568 \text{ zona_de_lavanderiaSi}_i + \varepsilon_i \end{aligned}$$

Nos permite dar una buena predicción del precio de un inmueble.

De esta forma se obtiene que:

- $(e^{0,2606} - 1) \times 100 = 29,8 \%$. Una vivienda en estrato 3 tiene un precio, en promedio, 29,8 % mayor que una vivienda en estrato (1 o 2).
- $(e^{0,5012} - 1) \times 100 = 65,0 \%$. Una vivienda en estrato 4 tiene un precio, en promedio, 65,0 % mayor que una vivienda en estrato (1 o 2).
- $(e^{0,5503} - 1) \times 100 = 73,4 \%$. Una vivienda en estrato 5 tiene un precio, en promedio, 73,4 % mayor que una vivienda en estrato (1 o 2).
- $(e^{0,6120} - 1) \times 100 = 84,4 \%$. Una vivienda en estrato 6 tiene un precio, en promedio, 84,4 % mayor que una vivienda en estrato (1 o 2).
- Un aumento del 1 % en el area se asocia con un aumento de 49 % en el precio.
- Un baño adicional genera un aumento de 10.7 % el precio.
- Un garaje adicional genera un aumento de 16.8 % en el precio.
- Un elevador adicional genera un aumento de 5.4 % en el precio.
- El hecho de que un inmueble sea casa aumento genera un aumento de 23.4 % en el precio.
- El hecho de que un inmueble tenga lavandería aumento genera un aumento de 23.4 % en el precio.

Como se puede apreciar, los B's de estrato en la interpretación no son los mismos que salen en el modelo, esto porque al realizar una consulta, se descubrió que la forma correcta de interpretarlos era usando una corrección de la forma $(e^{\hat{B}} - 1)$. La principal referencia puede verse aquí:

__ Halvorsen, R. & Palmquist, R. (1980). The Interpretation of Dummy Variables in Semilogarithmic Equations. American Economic Review, 70(3), 474–475. __

<https://scispace.com/pdf/the-interpretation-of-dummy-variables-in-semilogarithmic-54qeaggyyn.pdf>

7.1. Rango

El rango de predicción es en el cual el modelo puede dar predicciones acertadas con la confianza estadística obtenida, este es

```
## [1] 85000000 1530000000
```

Suficiente para dar un precio a bastantes inmuebles, pero no a todos los de bogotá.


8. Conclusiones y hallazgos relevantes

- Todos los modelos tuvieron R2 alto (mayor a 0.85)
- Antes de pensar en hacer transformaciones, todos los modelos fallaban la prueba de linealidad, lo que da a lugar a pensar de que sí existen relaciones no lineales necesarias para el modelo.
- Ajustes para validar un supuesto pueden dañar otros supuestos.
- Puede ser común encontrar segmentaciones ocultas en Precio con respecto a otras variables en conjuntos de datos inmobiliarios

- La inclusión de variables en un formato incorrecto puede cambiart todo, en este caso estrato fue previamente tratada como entera, de esta forma se encontraron dificultades an la prueba de los supuestos. Al incluirla como factor (categorica) este problema fue solucionado facilmente.
- Las observaciones que presentan apalancamiento no necesariamente son influyentes; de las 50 observaciones con apalancamiento, solo 14 se determinaron influyentes.

9. *Recomendaciones futuras*

- Obtener mas datos: mayor cantidad de datos hubiese podido crear significancia para otras variables, incluso pudiendo permitir que todos los supuestos se validen mas facilmente.
- Acotar la región de predicción: En el conjunto de datos existe concentración de valores en algunas variables, en particular en precio:



- Buscar una mejora en el modelo final: Aunque modelo_wls pasa todas la prueba de linealidad, es natural pensar en interacciones, por ejemplo, entre area y estrato, e incluso la inclusión de ‘administración’ en alguna potencia.

10. *Anexos*



10.1. 1. Modelos calculados con estrato numérico:



Nota: todo lo que esstá acá no se considera parte del análisis, por lo tanto las conclusiones presentes en esta sección no deben ser tomadas como verdaderas.

Durante el desarrollo del primer informe se habia trabajado con estrato como variable numérica, sin embargo durante la segunda entrega esto cambia para ser tratada como variable categórica, esto permitio que los supuestos de el primer modelo con pesos se cumplieran, es por ello que aquí se adjuntan los modelos que se habian intentado DESPUÉS del modelo con pesos cuando se usaba estrato como variable numerica:

10.1.1. Modelo con pesos y combinaciones

```
##
## Call:
## lm(formula = log(precio) ~ estrato + (log(area) * estrato) +
##     log(area) + I(log(area)^2) + banos + garajes + elevadores +
##     esCasa + zona_de_lavanderia + I(banos/log(area)) + I(garajes/log(area)),
##     data = propiedades, weights = 1/log(area)^2)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -0.107268 -0.023379 -0.001615  0.022649  0.147424
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)    23.093953   1.235026  18.699 < 0.0000000000000002 ***
## estrato         1.043317   0.115052   9.068 < 0.0000000000000002 ***
## log(area)      -3.486611   0.641735  -5.433  0.000000083976416 ***
## I(log(area)^2)  0.584957   0.084862   6.893  0.000000000015314 ***
## banos          -0.326825   0.215258  -1.518    0.1295
## garajes        -0.280047   0.281147  -0.996    0.3197
## elevadores      0.056576   0.009395   6.022  0.000000003193553 ***
## esCasaSi        0.142674   0.057863   2.466    0.0140 *
## zona_de_lavanderiaSi 0.030885  0.022860   1.351    0.1772
## I(banos/log(area)) 1.773847  0.875049   2.027    0.0431 *
## I(garajes/log(area)) 1.864665  1.168187   1.596    0.1110
## estrato:log(area) -0.213839  0.028032  -7.628  0.000000000000108 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.0375 on 539 degrees of freedom
## Multiple R-squared:  0.9056, Adjusted R-squared:  0.9037
## F-statistic: 470.2 on 11 and 539 DF,  p-value: < 0.00000000000000022
```





10.1.1.1. Comprobación de supuestos de modelo con pesos y combinacion de variables

10.1.1.2. * 1. Prueba de linealidad Y vs X - Test de Ramsey *

H_0 : El modelo está correctamente especificado (no hay variables omitidas ni no linealidad).

H_1 : El modelo está mal especificado (existen variables omitidas o no linealidad).

```
##  
## RESET test  
##  
## data: modelo_wls2  
## RESET = 3.6983, df1 = 2, df2 = 537, p-value = 0.0254
```

No se rechaza la hipótesis nula con $\alpha=0.05$, El modelo esta bien especificado

10.1.1.3. * 2. Prueba de Breusch Pagan - Homocedasticidad *

H_0 : $\text{Var}(\varepsilon_i) = \sigma^2$ (los errores tienen varianza constante)

H_1 : $\text{Var}(\varepsilon_i) \neq \sigma^2$ (existe heterocedasticidad)

```
##  
## studentized Breusch-Pagan test  
##  
## data: modelo_wls2  
## BP = 11.129, df = 11, p-value = 0.4325
```

NO se rechaza la hipótesis nula con $\alpha=0.05$, Existe homocedasticidad en el modelo completo

10.1.1.4. * 3. Prueba de autocorrelacion de los errores - Durbin Watson *

H_0 : $\rho = 0$ (no hay autocorrelación de los errores)

H_1 : $\rho \neq 0$ (los errores están correlacionados)

```
## lag Autocorrelation D-W Statistic p-value  
## 1 -0.087647 2.173546 0.046  
## Alternative hypothesis: rho != 0
```

NO se rechaza la hipotesis nula de que los errores son dependientes entre sí, se puede decir que los errores son independientes entre si (ortogonales)

10.1.1.5. * 4. Prueba de normalidad de los errores- Shapiro *

H_0 : $\varepsilon_i \sim N(0, \sigma^2)$ (los residuos son normalmente distribuidos)

H_1 : $\varepsilon_i \not\sim N(0, \sigma^2)$ (los residuos no son normales)

```
##
## Shapiro-Wilk normality test
##
## data: modelo_wls2$residuals
## W = 0.99466, p-value = 0.05177
```

NO se rechaza la hipótesis nula con un nivel de significancia de 0.05 de que el vector dado(residuales) tiene una distribución normal. **Existe normalidad de los residuales**

10.1.1.6. *VIF - verificación de inflación de varianza por colinealidad*

```
##          estrato          log(area)          I(log(area)^2)
##      343.655506          840.197855          996.938848
##          banos          garajes          elevadores
##      437.992900          670.326891          1.208587
##          esCasa  zona_de_lavanderia  I(banos/log(area))
##      1.096523          1.031670          334.097418
## I(garajes/log(area))  estrato:log(area)
##      615.387077          415.183219
```


Varios VIF sobrepasan 10 por mucho, **Hay inflación de varianza significativa por colinealidad** Aquí se llegó a un modelo que cumple los cuatro supuestos clásicos: - Linealidad X vs Y - Homocedasticidad - Errores independientes - Normalidad de los errores A pesar de lo anterior, los valores vif se dispararon porque se hicieron combinaciones entre variables, se intentará hacer un modelo más donde se pueda reducir ese VIF.



Para ello, se deberá evitar las combinaciones lineales, entonces se hará que algunos términos usen el área normal, pero otros usarán el logaritmo del área ,centrado por su media. Entonces así no habrá colinealidades tan fuertes .


10.1.2. Segundo Modelo con pesos y combinaciones (con centrado de log(area))

```
##
## Call:
## lm(formula = log(precio) ~ estrato * log_area_c + I(log_area_c^2) +
##     elevadores + esCasa + I(banos/area) + I(garajes/area), data = propiedades,
##     weights = 1/log(area)^2)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -0.109587 -0.023344 -0.001817  0.022890  0.147488
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)  18.572548   0.028728  646.496 < 0.0000000000000002 ***
## estrato       0.177757   0.009464  18.782 < 0.0000000000000002 ***
## log_area_c    1.255955   0.067846  18.512 < 0.0000000000000002 ***
## I(log_area_c^2) 0.552474   0.058813   9.394 < 0.0000000000000002 ***
## elevadores    0.058505   0.009343   6.262 0.000000000775994627 ***
```

```
## esCasaSi          0.146267    0.057964    2.523          0.0119 *
## I(banos/area)      6.241379    0.873965    7.141 0.0000000000002987480 ***
## I(garajes/area)    10.335353    1.092591    9.459 < 0.0000000000000002 ***
## estrato:log_area_c -0.205959    0.024704   -8.337 0.000000000000000631 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03757 on 542 degrees of freedom
## Multiple R-squared:  0.9047, Adjusted R-squared:  0.9033
## F-statistic: 643.2 on 8 and 542 DF,  p-value: < 0.00000000000000022
```







$\text{lm}(\log(\text{precio}) \sim \text{estrato} * \log_area_c + \text{l}(\log_area_c^2) + \text{elevadores} + \text{esCa} \dots$

10.1.2.1. Comprobación de supuestos del segundo modelo con pesos y combinacion de variables

10.1.2.2. * 1. Prueba de linealidad Y vs X - Test de Ramsey *

H_0 : El modelo está correctamente especificado (no hay variables omitidas ni no linealidad).

H_1 : El modelo está mal especificado (existen variables omitidas o no linealidad).

```
##
## RESET test
##
## data: modelo_final
## RESET = 3.6072, df1 = 2, df2 = 540, p-value = 0.02778
```

No se rechaza la hipótesis nula con $\alpha=0.05$, El modelo esta bien especificado

10.1.2.3. * 2. Prueba de Breusch Pagan - Homocedasticidad *

H_0 : $\text{Var}(\varepsilon_i) = \sigma^2$ (los errores tienen varianza constante)

H_1 : $\text{Var}(\varepsilon_i) \neq \sigma^2$ (existe heterocedasticidad)

```
##
## studentized Breusch-Pagan test
```

```
##
## data: modelo_final
## BP = 10.716, df = 8, p-value = 0.2183
```

NO se rechaza la hipótesis nula con $\alpha=0.05$, Existe homocedasticidad en el modelo completo

10.1.2.4. * 3. Prueba de autocorrelacion de los errores - Durbin Watson *

$$H_0 : \rho = 0 \quad (\text{no hay autocorrelación de los errores})$$

$$H_1 : \rho \neq 0 \quad (\text{los errores están correlacionados})$$

```
## lag Autocorrelation D-W Statistic p-value
## 1 -0.08464552 2.167524 0.052
## Alternative hypothesis: rho != 0
```

NO se rechaza la hipótesis nula de que los errores son dependientes entre sí, se puede decir que los errores son independientes entre si (ortogonales)

####* 4. Prueba de normalidad de los errores- Shapiro *

$$H_0 : \varepsilon_i \sim N(0, \sigma^2) \quad (\text{los residuos son normalmente distribuidos})$$

$$H_1 : \varepsilon_i \not\sim N(0, \sigma^2) \quad (\text{los residuos no son normales})$$

```
##
## Shapiro-Wilk normality test
##
## data: modelo_final$residuals
## W = 0.99375, p-value = 0.02251
```

Se rechaza la hipótesis nula con un nivel de significancia de 0.05 de que el vector dado(residuales) tiene una distribución normal. NO Existe normalidad de los residuales , ¡por poco no se rechaza!

10.1.2.5. * 5. Prueba de Varianza no constante*

```
## Non-constant Variance Score Test
## Variance formula: ~ fitted.values
## Chisquare = 1.313921, Df = 1, p = 0.25169
```

10.1.2.6. VIF - verificacion de inflación de varianza por colinealidad

##	estrato	log_area_c	I(log_area_c^2)	elevadores
##	2.315822	9.352321	1.467710	1.190376
##	esCasa	I(banos/area)	I(garajes/area)	estrato:log_area_c
##	1.095779	1.121591	1.982028	9.554411

Se logró el objetivo en este modelo: reducir el VIF, sin embargo se desajustó la normalidad de los errores, el valor p cambia a 0.03, lo que rompe el supuesto de normalidad por muy poco (Qqplot parece normal visualmente)

En este caso, se preferirá este modelo final, es el mejor modelo hallado porque no tiene de colinealidad y se cumplen todos los supuestos, excepto el de normalidad con un nivel de significancia de 0.05 (si se usara un alpha de 0.01 - 0.03 se podría no rechazar H_0 , indicando normalidad)

““